LAPORAN AKHIR DATA SAINS DAN ANALISIS

“MBTI Dataset”



Oleh :

Muhammad Rais Asy Syauqi (1103223178)

Muhammad Naufal Firdaus (1103220083)

Hasan Al Banna (1103223142)

PROGRAM STUDI SI S1 TEKNIK KOMPUTER

FAKULTAS TEKNIK ELEKTRO

UNIVERSITAS TELKOM

2024

DAFTAR ISI

BAB I BUSINESS UNDERSTANDING 1
1.1 Latar Belakang 1
1.2 Analisis Awal Dataset 1
1.3 Tujuan Bisnis 1
1.4 Manfaat 2
1.5 Rumusan Masalah 2
BAB II EXPLORATORY DATA ANALYSIS 3
2.1 Deskripsi Data dan Karakteristik Atribut 3
Gambar 2.1 Informasi Data 3
Gambar 2.2 Data Describe 3
2.2 Korelasi Antar Data 4
2.2.1 Matriks Korelasi 4
Gambar 2.3 Heatmap Korelasi Data 4
2.2.2 Korelasi Variabel terhadap Personality 5
Gambar 2.4 Distribusi Variabel Data 5
Gambar 2.5 Age Vs Personality 6
Gambar 2.6 Gender Vs Personality 7
Gambar 2.7 Introversion Score Vs Personality 7
Gambar 2.9 Thinking Score Vs Personality 8
Gambar 2.10 Judging Score Vs Personality 9
Gambar 2.11 Sensing Score Vs Personality 10
BAB III DATA PREPROCESSING 11
3.1 Menghapus data nan/null 11
Gambar 3.1 Missing Data 11
Gambar 3.2 Solve Missing Data 11
3.2 Menghapus data duplikat 12
Gambar 3.3 Jumlah Data Duplikat 12
Gambar 3.4 Hasil Penghapusan Duplikat Data 12
3.3 Transformasi Fitur Kategorikal 12
Gambar 3.5 Encode Variabel Gender 12
Gambar 3.6 Encode Tipe Data Menjadi Numerik 13
3.4 Menghilangkan Outlier 13

Berdasarkan hasil pemeriksaan outlier dengan boxplot, didapat hasil seperti berikut : 13
Gambar 3.7 Data Outlier 13
Gambar 3.8 Data Outlier dengan IQR 14
3.5 Balancing data 14
Gambar 3.10 Counter Data Setelah Penanganan Outlier 15
BAB IV FEATURE SELECTION 16
4.1 SelectKBest 16
Gambar 4.1 Feature Selection Dengan SelectKBest 16
4.2 Random Forest Feature Importance 16
Gambar 4.2 Feature Selection Dengan RandomForest Feature Importance 16
4.3 Gradient Boosting Classifier 17
Gambar 4.3 Feature Selection Dengan Gradient Boosting Classifier 17
4.4 XGBoost Classifier 17
BAB V MODELLING 18
5.1 StandardScaler 18
Gambar 5.1 Penanganan Dengan Penanganan StandardScaler 18
5.2 MinMaxScaler 18
Gambar 5.2 Modeling Dengan Penanganan MinMaxScaler 18
5.3 RobustScaler 18
Gambar 5.3 Modeling Dengan Penanganan RobustScaler 19
5.4 IQR (Interquartile Range) 19
Gambar 5.4 Modeling Dengan Penanganan IQR 19
5.6 Perbandingan Seluruh Metode 19
BAB VI DEPLOYING 21
6.1 Streamlit 21
Gambar 6.1 Modeling Dengan Penanganan IQR 21

BAB I BUSINESS UNDERSTANDING

1.1 Latar Belakang

Dalam era modern yang semakin kompleks, pemahaman terhadap kepribadian individu menjadi aspek penting dalam berbagai bidang, seperti psikologi, pendidikan, dan sumber daya manusia. Kepribadian seseorang dapat mempengaruhi cara mereka berpikir, berinteraksi, dan mengambil keputusan dalam kehidupan sehari-hari. Oleh karena itu, analisis terhadap faktor-faktor yang membentuk kepribadian menjadi suatu kajian yang menarik dan memiliki manfaat luas.

Dataset yang digunakan ini berisi informasi mengenai karakteristik individu yang mencakup usia, jenis kelamin, tingkat pendidikan, serta berbagai nilai psikologis, seperti *introversion*, *sensing*, *thinking*, dan *judging*. Selain itu, dataset ini juga mencakup data mengenai minat individu serta tipe kepribadian mereka berdasarkan indikator MBTI (Myers-Briggs *Type Indicator*). Dengan adanya *dataset* ini, diharapkan pengguna dapat memahami tipe kepribadiannya yang dapat membantu dalam memberikan rekomendasi di bidang seperti rekrutmen, pendidikan, dan pengembangan diri.

1.2 Analisis Awal Dataset

Dataset ini berisi informasi tentang berbagai tipe kepribadian berdasarkan indikator MBTI, serta beberapa variabel pendukung seperti usia, gender, tingkat pendidikan, dan minat. Tujuan dari analisis ini adalah untuk memahami distribusi data dan hubungan antar variabel yang dapat digunakan dalam berbagai aplikasi, seperti rekomendasi karier, penelitian psikologi, dan pengembangan produk berbasis kepribadian.

Adapun dataset tersebut memiliki 43.744 entri dengan 9 kolom. Kolom yang tersedia diantara lain adalah :

- Age: Usia responden.
- Gender: Jenis kelamin (Male/Female).
- Education: Tingkat pendidikan.
- Introversion Score: Skor introversi.
- Sensing Score: Skor sensing.
- Thinking Score: Skor berpikir.
- Judging Score: Skor judging.
- Interest: Minat responden (Arts, Sports, Others, dll.).
- Personality: Tipe kepribadian MBTI.

Dataset ini memiliki potensi penggunaan yang luas dalam berbagai bidang. Beberapa tipe kepribadian cenderung memiliki minat yang spesifik. Misalnya, ada kecenderungan bahwa tipe tertentu lebih tertarik pada seni, sementara yang lain lebih dominan dalam olahraga.

1.3 Tujuan Bisnis

Tujuan utama dari analisis ini adalah membangun model prediksi yang dapat mengklasifikasikan tipe kepribadian seseorang berdasarkan faktor-faktor psikologis dan demografis yang tersedia dalam dataset. Tujuan bisnis yang ingin dicapai meliputi:

- Mengembangkan Model Prediksi Kepribadian
    - Menganalisis dan mengolah dataset untuk membangun model machine learning yang mampu mengklasifikasikan tipe kepribadian seseorang berdasarkan indikator MBTI (Myers-Briggs Type Indicator).
- Meningkatkan Efektivitas dalam Rekrutmen dan SDM
    - Membantu perusahaan dalam proses rekrutmen dengan memberikan wawasan tentang kepribadian kandidat, sehingga dapat menempatkan mereka pada posisi kerja yang paling sesuai.
- Membantu Siswa dan Mahasiswa dalam Pendidikan
    - Menyediakan alat bantu bagi siswa atau mahasiswa dalam memilih jalur pendidikan yang sesuai dengan karakteristik kepribadian mereka.
- Memberikan Rekomendasi untuk Pengembangan Diri
    - Memberikan wawasan bagi individu agar lebih memahami kepribadian mereka sendiri dan bagaimana mereka dapat mengembangkan potensi mereka di berbagai bidang.

Dengan mencapai tujuan-tujuan ini, model yang dikembangkan diharapkan dapat memberikan manfaat yang luas dalam berbagai sektor, termasuk psikologi, pendidikan, dan manajemen sumber daya manusia.

1.4 Manfaat

- Rekrutmen Perusahaan : Admin HR dapat menilai kelayakan kandidat karyawan dan menyesuaikan posisi kerja dengan kepribadiannya.
- Pendidikan : Para siswa dapat menyesuaikan jalur pendidikan yang akan ditempuh sesuai dengan kepribadiannya.
- *Self-Development* : Memberikan wawasan kepada individu tentang kecenderungan kepribadiannya agar dapat mengembangkan diri di masa mendatang.

1.5 Rumusan Masalah

1. Bagaimana cara mengkodekan data kategori seperti gender dan pendidikan agar dapat diproses oleh model?
2. Bagaimana menangani data yang tidak lengkap atau tidak seimbang dalam distribusi tipe kepribadian?
3. Bagaimana cara memprediksi tipe kepribadian seseorang dari kombinasi faktor psikologis dan minat mereka?
4. Bagaimana agar data yang digunakan cukup representatif untuk membangun model prediksi tipe kepribadian yang akurat?

BAB II EXPLORATORY DATA ANALYSIS

2.1 Deskripsi Data dan Karakteristik Atribut

Berdasarkan hasil eksplorasi yang telah dilakukan, dataset ini memiliki data yang terdiri dari 43.744 baris dan 9 kolom, dengan atribut sebagai berikut:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 43744 entries, 0 to 43743
Data columns (total 9 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   Age                 43742 non-null  float64
 1   Gender              43742 non-null  object
 2   Education           43744 non-null  int64
 3   Introversion Score  43741 non-null  float64
 4   Sensing Score       43741 non-null  float64
 5   Thinking Score      43744 non-null  float64
 6   Judging Score       43740 non-null  float64
 7   Interest            43741 non-null  object
 8   Personality         43742 non-null  object
dtypes: float64(5), int64(1), object(3)
memory usage: 3.0+ MB
```

Gambar 2.1 Informasi Data

	Age	Gender	Education	Introversion Score	Sensing Score	Thinking Score	Judging Score	Interest	Personality
count	43730.000000	43730.00000	43730.000000	43730.000000	43730.000000	43730.000000	43730.000000	43730.000000	43730.000000
mean	27.437228	0.44777	0.229019	4.588074	5.780149	5.419428	5.391221	2.300777	7.501006
std	4.893707	0.49727	0.420206	2.902638	1.241654	2.900941	1.442422	1.544324	4.609984
min	18.000000	0.00000	0.000000	0.000150	0.000000	0.000320	0.000000	0.000000	0.000000
25%	24.000000	0.00000	0.000000	2.066840	4.953455	2.895083	4.512348	1.000000	4.000000
50%	27.000000	0.00000	0.000000	4.261200	6.162937	5.771310	5.771939	2.000000	8.000000
75%	30.000000	1.00000	0.000000	7.084570	6.623083	7.924275	6.410014	4.000000	12.000000
max	52.000000	1.00000	1.000000	9.999920	9.803837	9.999770	10.000000	5.000000	16.000000

Gambar 2.2 Data Describe

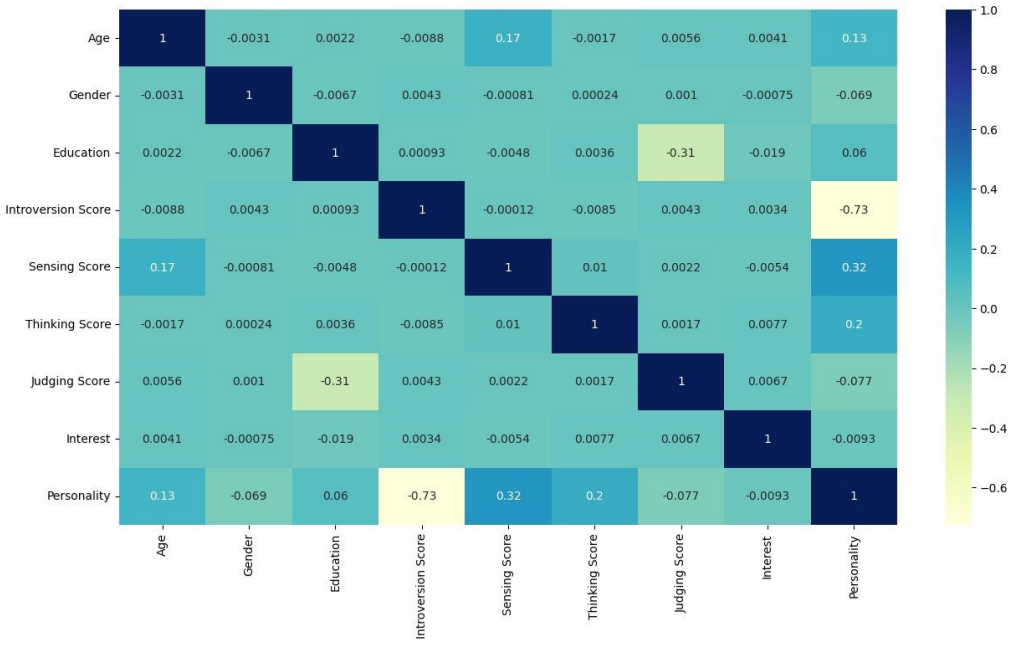
1. Age
    - Tipe Data: float64
    - Rentang: 18 - 52 tahun
    - Rata-rata: 27,4 tahun
    - Penyebaran data cukup merata dengan standar deviasi sekitar 4,89
2. Gender
    - Tipe Data: object
    - Berisi kategori seperti "Male" dan "Female"
3. Education
    - Tipe Data: int64
    - Nilai unik: 0 dan 1
4. Introversion Score (Skor Introversi)
    - Tipe Data: float64
    - Rentang: 0.19 - 999.99
    - Rata-rata sekitar 414.62
5. Sensing Score
    - Tipe Data: float64

6. Thinking Score
    - Tipe Data: float64
    - Rentang: 0.19 - 999.97
    - Rata-rata sekitar 489.06
7. Judging Score
    - Tipe Data: object
8. Interest
    - Tipe Data: object
    - Berisi kategori seperti "Arts", "Sports", "Others", "Unknown"
9. Personality
    - Tipe Data: object
    - Berisi tipe MBTI (seperti ENTP, INTP, ESFP, dll.)

2.2 Korelasi Antar Data

Berikut merupakan korelasi yang kami dapatkan berdasarkan eksplorasi yang telah dilakukan:

2.2.1 Matriks Korelasi



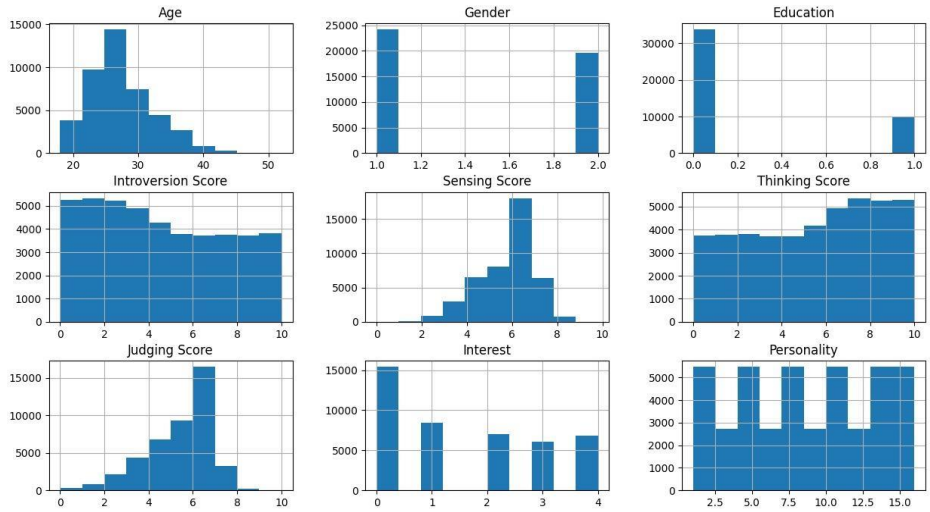
Gambar 2.3 Heatmap Korelasi Data

- Korelasi Positif
    - Sensing Score vs Personality (0.32), Artinya, semakin tinggi Sensing Score, semakin tinggi kemungkinan tipe personality tertentu.
    - Thinking Score vs Personality (0.2), Ada hubungan positif, meskipun tidak terlalu kuat.

- Korelasi Negatif
  - Introversion Score vs Personality (-0.73), Semakin tinggi Introversion Score, semakin rendah kemungkinan tipe personality tertentu.
  - Judging Score vs Education (-0.31), Menunjukkan bahwa orang dengan pendidikan lebih tinggi cenderung memiliki skor Judging lebih rendah.
  - Gender vs Personality (-0.069), Korelasi negatif lemah, menunjukkan bahwa gender tidak terlalu mempengaruhi personality.

2.2.2 Korelasi Variabel terhadap Personality

1. Histogram Distribusi Data

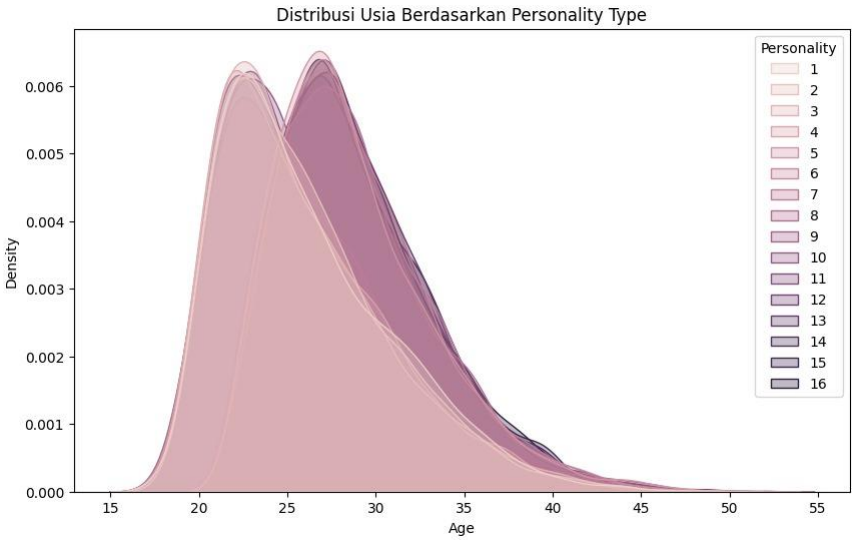


Gambar 2.4 Distribusi Variabel Data

- Age(usia)
  - Distribusi usia menunjukkan bahwa mayoritas individu berusia antara 20 hingga 35 tahun, dengan puncaknya sekitar 25–30 tahun.
  - Usia di atas 40 tahun relatif jarang.
- Gender (Jenis Kelamin)
  - Terdapat **dua kategori**, **1 = laki-laki, dan 2 = perempuan**
  - Jumlah individu dalam kedua kategori ini relatif seimbang.
- Education (Pendidikan)
  - Nilai 1 menunjukkan bahwa setidaknya suatu individu tersebut berpendidikan minimal sarjana (atau lebih).
  - Nilai 0 menunjukkan bahwa individu tersebut berpendidikan dibawah sarjana (lulusan SMA ke bawah).
  - Mayoritas memiliki nilai 0, yang menunjukkan bahwa sebagian besar peserta tidak memiliki pendidikan sarjana (atau lebih).

- Introversion Score
    - Memiliki rentang 0 hingga 10, yang mewakili kecenderungan individu terhadap introversi atau ekstroversi. Skor yang lebih tinggi menunjukkan kecenderungan yang lebih besar terhadap ekstroversi.
- Sensing Score
    - Memiliki rentang 0 hingga 10, yang mewakili preferensi individu terhadap sensing atau intuisi. Skor yang lebih tinggi menunjukkan preferensi terhadap sensing.
- Thinking Score
    - Menunjukkan preferensi individu terhadap berpikir (thinking) atau merasakan (feeling). Skor yang lebih tinggi menunjukkan preferensi terhadap berpikir.
- Judging Score
    - Mewakili preferensi individu terhadap menilai (judging) atau memahami (perceiving). Skor yang lebih tinggi menunjukkan preferensi terhadap menilai.
- Interest
    - Dibagi menjadi 4 kategori. Individu ini memiliki kecenderungan dengan ketertarikan pada :
        - 1 : Arts
        - 2 : Sport
        - 3 : Teknologi
        - 4 : Others
        - 5 : Unknown

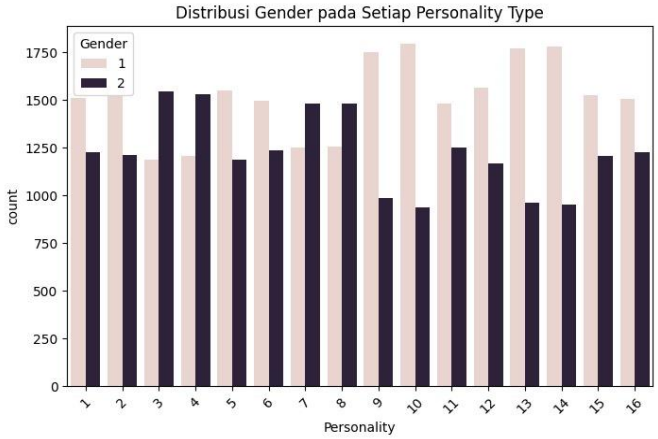
2. Age Vs Personality



Gambar 2.5 Age Vs Personality

Terlihat bahwa usia mayoritas berkisar antara 20 hingga 35 tahun, dengan dua puncak utama sekitar usia 22-23 tahun dan 28-30 tahun. Setelah usia 35 tahun ke atas, jumlah individu dengan semua tipe kepribadian menurun drastis.

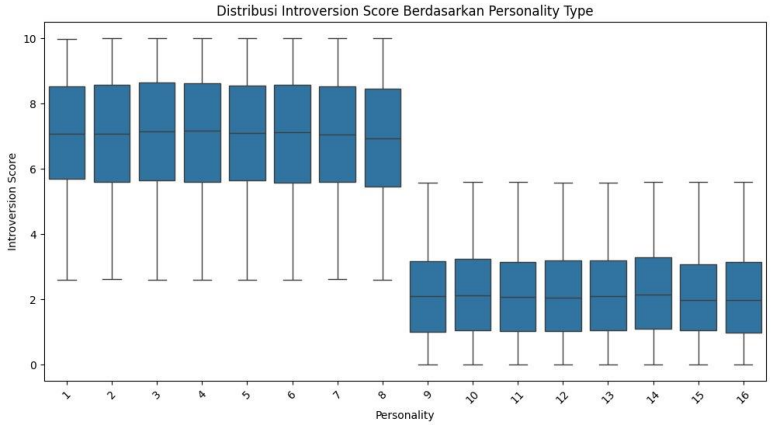
3. Distribusi Gender terhadap Personality



Gambar 2.6 Gender Vs Personality

- Gender 1 (Male) lebih dominan dalam beberapa tipe kepribadian, terutama pada tipe 10, 12, dan 13.
- Gender 2 (Female) lebih rendah jumlahnya dibandingkan Gender 1 pada mayoritas tipe kepribadian, tetapi mendekati seimbang pada beberapa tipe seperti 4, 8, dan 16.
- Terdapat perbedaan yang cukup signifikan antara kedua gender di beberapa tipe kepribadian, misalnya pada Tipe 10 dan 12, di mana Gender 1 jauh lebih banyak dibandingkan Gender 2.
- Beberapa tipe kepribadian memiliki distribusi yang hampir merata, seperti Tipe 4, 6, 8, dan 16, yang menunjukkan bahwa gender tidak memiliki pengaruh besar pada distribusi kepribadian dalam kelompok ini.
- Tipe 9 dan 10 menunjukkan kesenjangan terbesar antara Gender 1 dan Gender 2, yang bisa menjadi indikasi bahwa kepribadian dalam kategori ini lebih banyak dimiliki oleh satu gender tertentu.

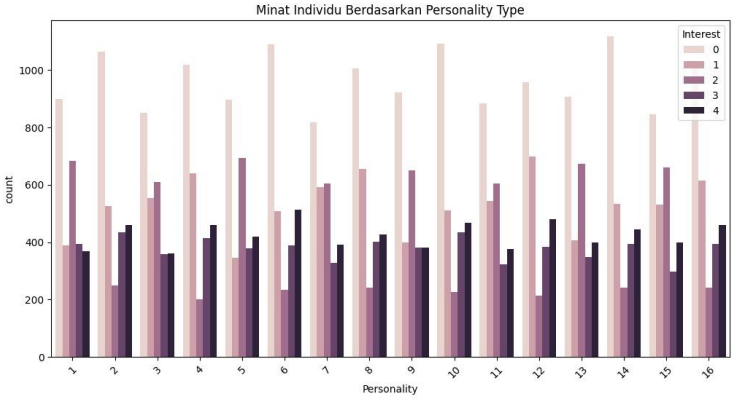
4. Distribusi Introversion Score Berdasarkan Personality Type



Gambar 2.7 Introversion Score Vs Personality

- Kelompok pertama (1-8): memiliki introversion score yang cenderung lebih tinggi, dengan median sekitar 7-8 dan rentang interkuartil yang lebar
- Kelompok kedua (9-16): memiliki introversion score yang lebih rendah, dengan median sekitar 3-4 dengan rentang interkuartil yang lebih kecil
- Kelompok pertama memiliki distribusi skor yang lebih terkonsentrasi di nilai tinggi atau introvert
- Kelompok kedua memiliki distribusi yang lebih merata di rendah atau ekstrovert

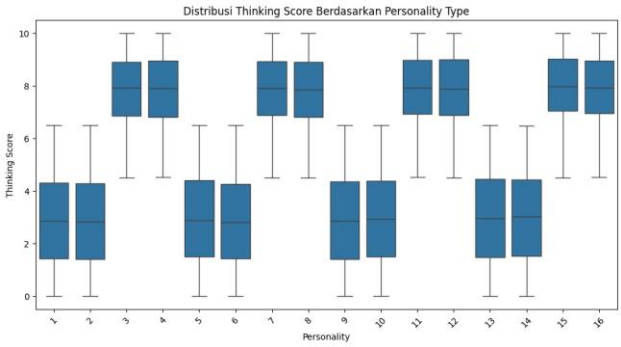
5. Minat Individu Berdasarkan Personality Type



Gambar 2.8 Interest Vs Personality

- Kategori “0” (warna terang) yaitu Unknown memiliki jumlah tertinggi dalam setiap tipe kepribadian.
- Kategori “4” (warna gelap) yaitu Others memiliki jumlah paling sedikit, tetapi tetap ada dalam semua tipe MBTI.
- Pola distribusi hampir seragam untuk semua 16 tipe kepribadian, dengan sedikit variasi dalam jumlah individu di setiap tingkat minat.
- Tidak ada perbedaan mencolok antara tipe kepribadian dalam hal jumlah minat

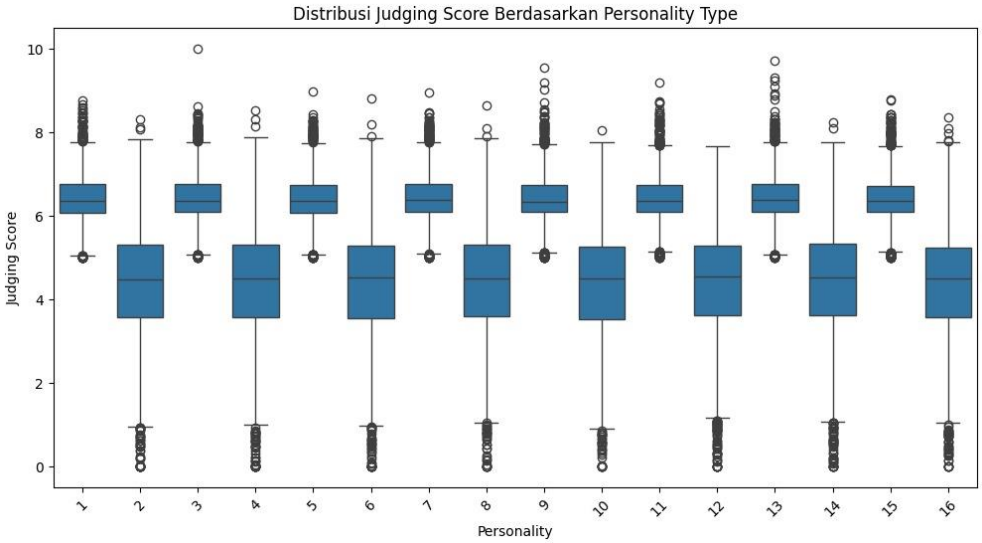
6. Distribusi Thinking Score Berdasarkan Personality Type



Gambar 2.9 Thinking Score Vs Personality

- Median (garis dalam box): menunjukkan nilai tengah Thinking Score dalam setiap tipe.
- Interquartile Range (IQR – area dalam box): menggambarkan rentang nilai Thinking Score yang paling umum.
- Whiskers (garis vertikal di atas dan bawah box): menunjukkan rentang nilai yang lebih luas, kecuali outlier.
- Beberapa tipe kepribadian memiliki Thinking Score yang lebih tinggi (median di atas 7–8).
- Tipe lainnya memiliki Thinking Score yang lebih rendah (median di sekitar 3–4).
- Variasi Thinking Score dalam tiap tipe berbeda, beberapa lebih tersebar, sementara yang lain lebih terkonsentrasi.

7. Distribusi Judging Score Berdasarkan Personality Type

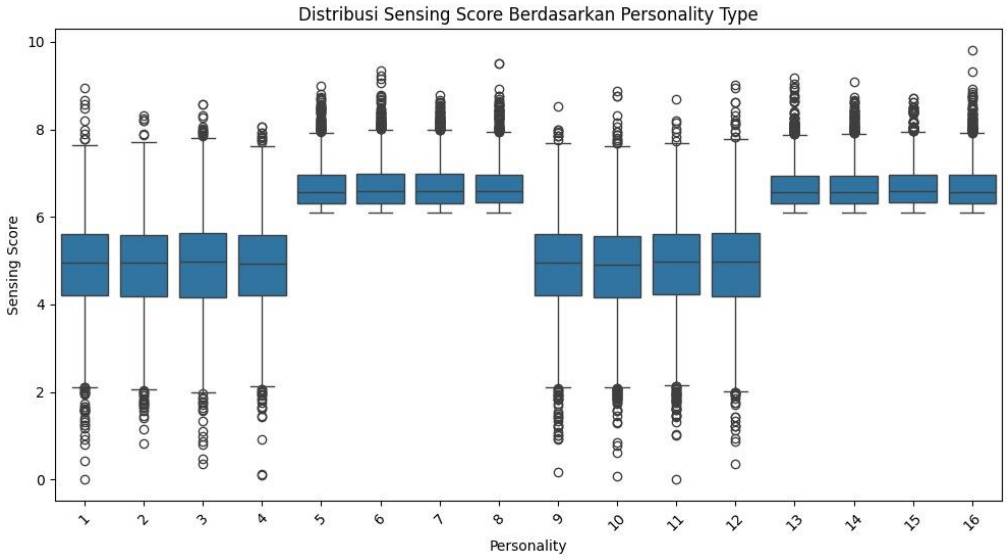


Gambar 2.10 Judging Score Vs Personality

- Median (garis dalam box): menunjukkan nilai tengah Judging Score dalam setiap tipe.
- Interquartile Range (IQR – area dalam box): menggambarkan rentang nilai Judging Score yang paling umum.
- Whiskers (garis vertikal di atas dan bawah box): menunjukkan rentang nilai yang lebih luas, kecuali outlier.
- Titik-titik di luar whiskers: menunjukkan outlier atau nilai yang jauh dari distribusi utama.
- Beberapa tipe kepribadian memiliki Judging Score yang lebih tinggi (median sekitar 6–7).
- Tipe lainnya memiliki Judging Score yang lebih rendah (median sekitar 4–5).

- Hampir semua tipe memiliki outlier di atas dan di bawah rentang utama.
- Variasi skor dalam tiap tipe menunjukkan perbedaan tingkat Judging di antara berbagai tipe MBTI.

8. Distribusi Sensing Score Personality Type



Gambar 2.11 Sensing Score Vs Personality

- Median (garis dalam box): nilai tengah Sensing Score dalam setiap tipe.
- Interquartile Range (IQR – area dalam box): rentang nilai Sensing Score yang paling umum.
- Whiskers (garis vertikal di atas dan bawah box): rentang nilai yang lebih luas, kecuali outlier.
- Titik-titik di luar whiskers: outlier atau nilai yang jauh dari distribusi utama.
- Beberapa tipe memiliki Sensing Score yang lebih tinggi (median sekitar 7).
- Tipe lainnya memiliki Sensing Score yang lebih rendah (median sekitar 4–5).
- Hampir semua tipe memiliki outlier di bagian atas dan bawah.
- Variasi skor dalam tiap tipe menunjukkan perbedaan tingkat Sensing di antara berbagai tipe MBTI.

BAB III DATA PREPROCESSING

3.1 Menghapus data nan/null

Berdasarkan hasil pemeriksaan yang dilakukan, ada beberapa data *missing* sebagai berikut :

	0
Age	2
Gender	2
Education	0
Introversion Score	3
Sensing Score	3
Thinking Score	0
Judging Score	4
Interest	3
Personality	2

dtype: int64

Gambar 3.1 Missing Data

Dari data diatas, diketahui bahwa 19 data didapati nan/null, maka dilakukan cleansing dengan menghapus data yang nan/null tadi, setelah dilakukan cleansing dengan fungsi dropna, maka tidak ada lagi data yang nan/null seperti berikut :

	0
Age	0
Gender	0
Education	0
Introversion Score	0
Sensing Score	0
Thinking Score	0
Judging Score	0
Interest	0
Personality	0

dtype: int64

Gambar 3.2 Solve Missing Data

3.2 Menghapus data duplikat

Berdasarkan hasil pengecekan jumlah data yang terduplikasi, terdapat data yang duplikat sebagai berikut :

```
data.duplicated().sum()
```

```
np.int64(1027)
```

Gambar 3.3 Jumlah Data Duplikat

Dari data diatas, diketahui bahwa 1027 data didapati terduplikasi, maka dilakukan cleansing dengan menghapus data duplikat tadi, setelah dilakukan cleansing dengan fungsi **drop_duplicates**, maka tidak ada lagi data duplikat seperti berikut :

```
data.duplicated().sum()
```

```
np.int64(0)
```

Gambar 3.4 Hasil Penghapusan Duplikat Data

3.3 Transformasi Fitur Kategorikal

Fitur kategorikal diubah menjadi bentuk numerik agar bisa diproses oleh algoritma machine learning:

- Fitur 'Gender' di-mapping ke dalam nilai numerik:
  - 'Male' → 0, 'Female' → 1.

```
[ ] data['Gender'] = data['Gender'].map({'Male': 0, 'Female': 1})
```

```
data.head()
```

	Age	Gender	Education	Introversion Score	Sensing Score	Thinking Score	Judging Score	Interest	Personality
0	21.0	1.0	1	5.89208	2.144395	7.32363	5.462224	Arts	ENTP
1	24.0	1.0	1	2.48366	3.206188	8.06876	3.765012	Unknown	INTP
2	26.0	1.0	1	7.02910	6.469302	4.16472	5.454442	Others	ESFP
3	30.0	0.0	0	5.46525	4.179244	2.82487	5.080477	Sports	ENFJ
4	31.0	1.0	0	3.59804	6.189259	5.31347	3.677984	Others	ISFP

Gambar 3.5 Encode Variabel Gender

- Fitur 'Personality' dan 'Interest' di-encode menggunakan LabelEncoder() dari Scikit-learn.

```
[ ]  encoder = LabelEncoder()
     data["Personality"] = encoder.fit_transform(data["Personality"])

     data['Interest'] = encoder.fit_transform(data['Interest'])

[ ]  data.info()

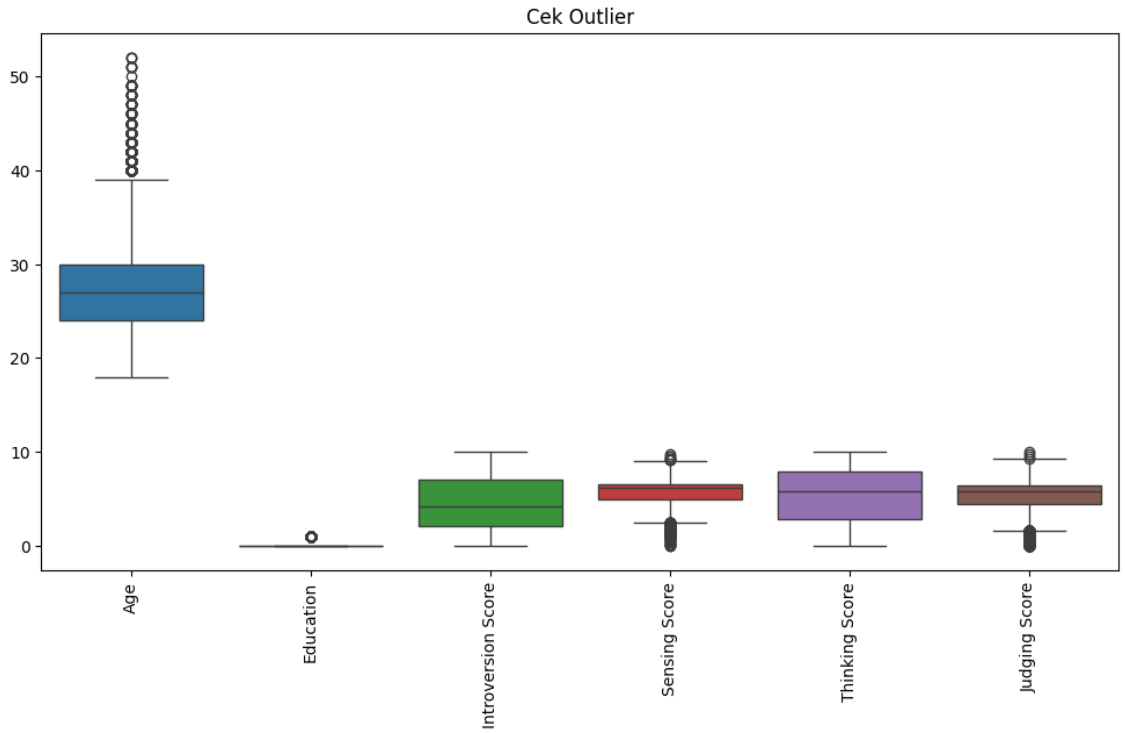
     <class 'pandas.core.frame.DataFrame'>
     Index: 42717 entries, 0 to 43743
     Data columns (total 9 columns):
      #   Column              Non-Null Count  Dtype
     ---  ------              --------------  -----
      0   Age                 42715 non-null  float64
      1   Gender              42715 non-null  float64
      2   Education           42717 non-null  int64
      3   Introversion Score  42714 non-null  float64
      4   Sensing Score       42714 non-null  float64
      5   Thinking Score      42717 non-null  float64
      6   Judging Score       42713 non-null  float64
      7   Interest            42717 non-null  int64
      8   Personality         42717 non-null  int64
     dtypes: float64(6), int64(3)
     memory usage: 3.3 MB
```

Gambar 3.6 Encode Tipe Data Menjadi Numerik

Transformasi ini menghindari masalah dalam pemrosesan numerik serta memungkinkan model untuk mengenali pola dari kategori yang sebelumnya bersifat teks.

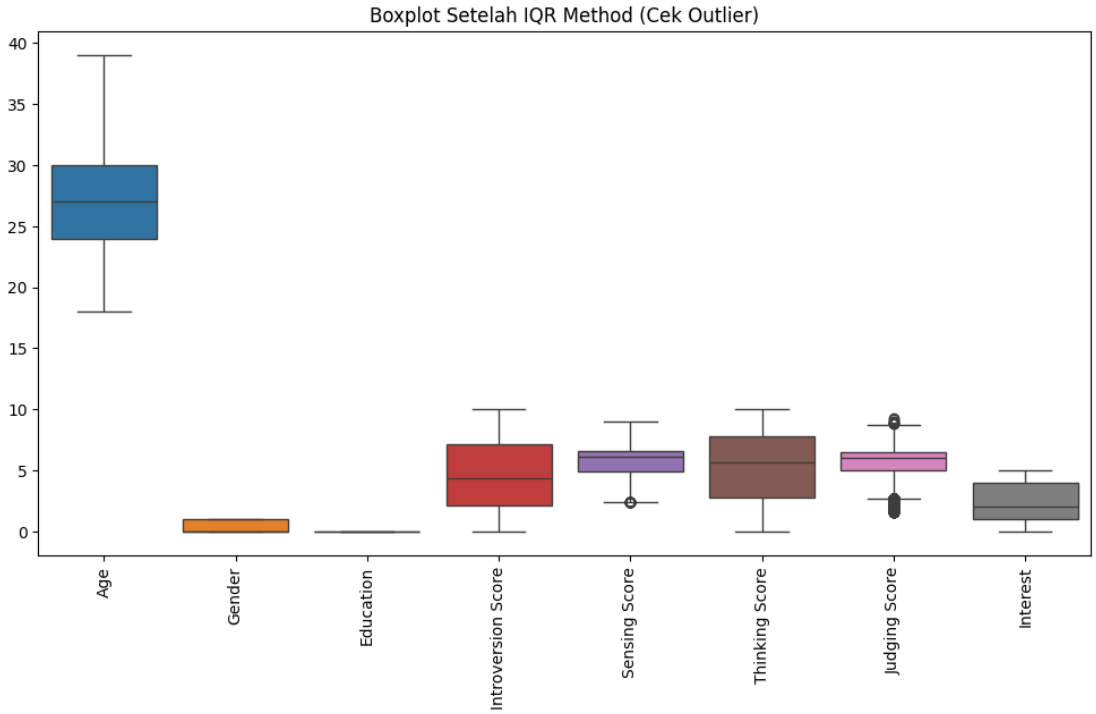
3.4 Menghilangkan Outlier

Berdasarkan hasil pemeriksaan outlier dengan boxplot, didapat hasil seperti berikut :



Gambar 3.7 Data Outlier

Setelah diketahui adanya outlier pada data, dilakukan cleansing outlier dengan metode IQR, dan berikut boxplot setelah menggunakan metode IQR :



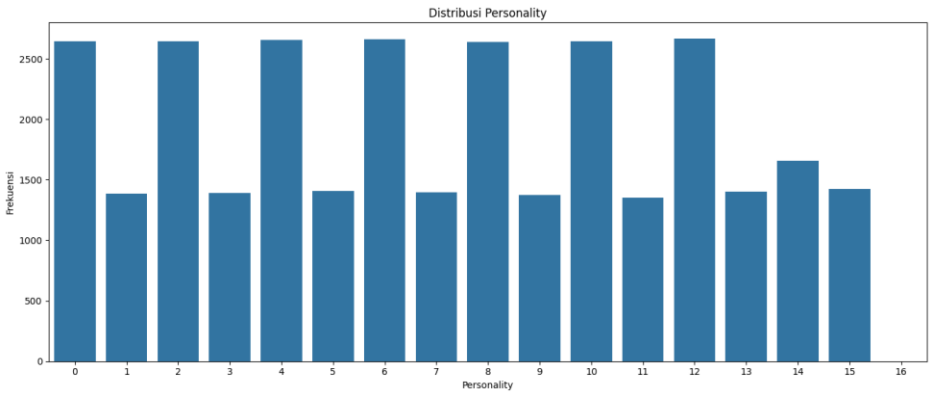
Gambar 3.8 Data Outlier dengan IQR

Dari boxplot diatas terlihat masih terdapat beberapa titik outlier pada sensing score dan judging score, hal tersebut terjadi karena Metode IQR hanya menghapus outlier berdasarkan rumus:
Lower Bound = Q1−1.5×IQR, Upper Bound=Q3+1.5×IQR

sehingga hanya menghapus sebagian data yang ekstrim, dan membiarkan data borderline (yang masih sedikit di luar batas) tetap ada.

3.5 Balancing data

Berdasarkan hasil pemeriksaan distribusi data di target (Personality Type), didapat hasil sebagai berikut :

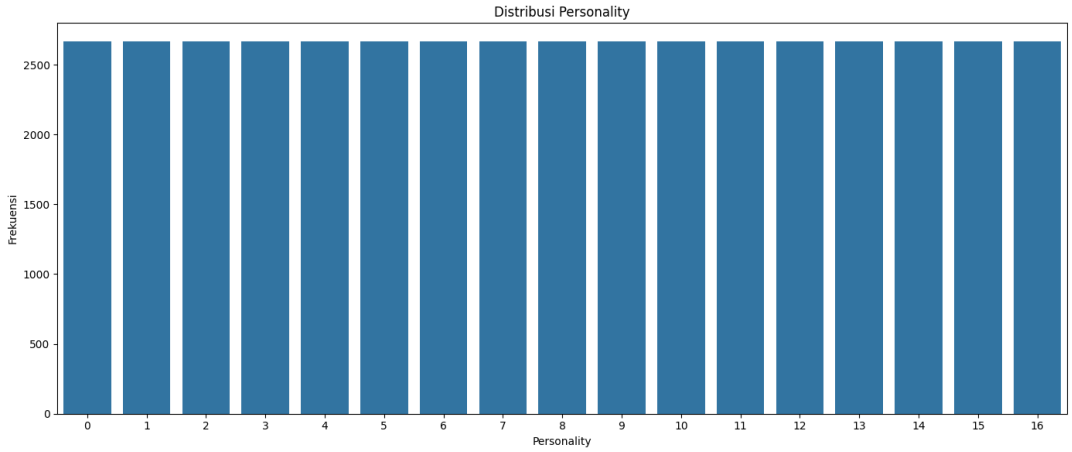


Gambar 3.9 Distribusi Data Setelah Penanganan Outlier

```
Counter({0: 2644,
         13: 1402,
         12: 2665,
         6: 2664,
         1: 1387,
         10: 2644,
         7: 1394,
         4: 2658,
         14: 1658,
         8: 2637,
         15: 1423,
         2: 2642,
         9: 1373,
         5: 1408,
         3: 1391,
         11: 1351,
         16: 1})
```

Gambar 3.10 Counter Data Setelah Penanganan Outlier

Setelah dilakukan penghapusan data yang termasuk sebagai outlier, ternyata terjadi ketidakseimbangan data pada target, sehingga harus dilakukannya balancing dengan menggunakan RandomOverSampler, dan didapat hasil sebagai berikut :



Gambar 3.11 Distribusi Data Setelah Sampling

```
Counter({0: 2665,
         13: 2665,
         12: 2665,
         6: 2665,
         1: 2665,
         10: 2665,
         7: 2665,
         4: 2665,
         14: 2665,
         8: 2665,
         15: 2665,
         2: 2665,
         9: 2665,
         5: 2665,
         3: 2665,
         11: 2665,
         16: 2665})
```

Gambar 3.12 Counter Data Setelah Sampling

BAB IV FEATURE SELECTION

4.1 SelectKBest

```
X = data.drop('Personality', axis=1)
y = data['Personality']

selector = SelectKBest(score_func=f_regression, k=5)
X_new = selector.fit_transform(X, y)

# Fitur terpilih
selected_features = X.columns[selector.get_support()]
print(selected_features)
```

```
Index(['Age', 'Introversion Score', 'Sensing Score', 'Thinking Score',
       'Judging Score'],
      dtype='object')
```

Gambar 4.1 Feature Selection Dengan SelectKBest

Dengan menggunakan metode statistik f_regression, lima fitur terbaik dipilih secara otomatis:

a. Age
b. Introversion Score
c. Sensing Score
d. Thinking Score
e. Judging Score

4.2 Random Forest Feature Importance

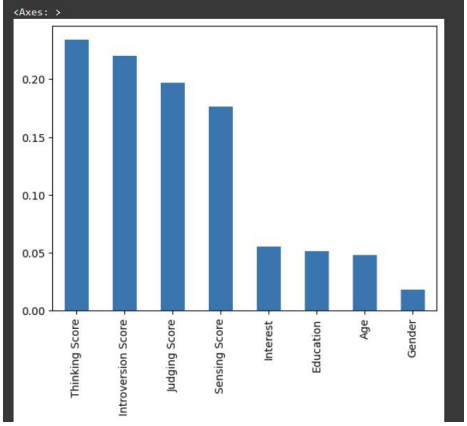
Model Random Forest menunjukkan bahwa fitur paling penting adalah:

- Thinking Score
- Introversion Score
- Judging Score
- Sensing Score
- Interest, Education, Age, Gender (kurang signifikan)

```
model = RandomForestClassifier()
model.fit(X, y)

importances = model.feature_importances_

# Urutkan dan tampilkan
feature_importance = pd.Series(importances, index=X.columns)
feature_importance.sort_values(ascending=False).plot(kind='bar')
```



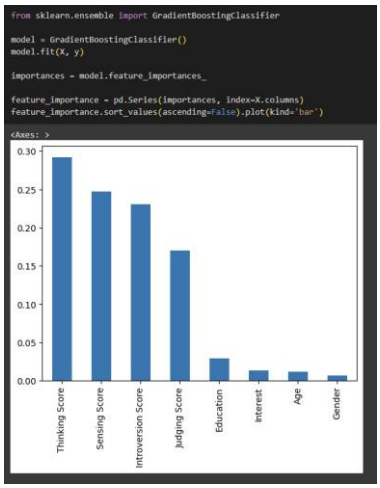
Gambar 4.2 Feature Selection Dengan RandomForest Feature Importance

4.3 Gradient Boosting Classifier

Model ini juga mendukung pentingnya:

- Thinking Score
- Sensing Score
- Introversion Score
- Judging Score

Fitur-fitur seperti Education, Interest, Age, dan Gender memiliki pengaruh yang kecil.



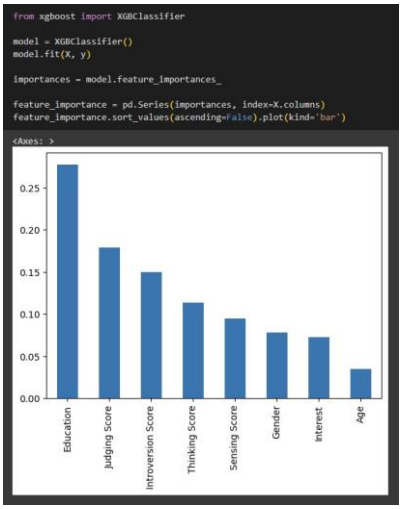
Gambar 4.3 Feature Selection Dengan Gradient Boosting Classifier

4.4 XGBoost Classifier

Uniknya, pada model ini Education menjadi fitur paling dominan, diikuti oleh:

- Judging Score
- Introversion Score
- Thinking Score
- Sensing Score

Perbedaan ini menunjukkan bahwa hasil feature importance bisa berbeda tergantung pada algoritma yang digunakan.

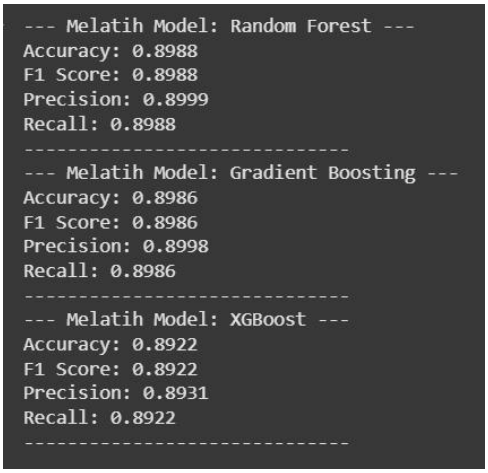


Gambar 4.4 Feature Selection Dengan XGBoost Classifier

BAB V MODELLING

5.1 StandardScaler

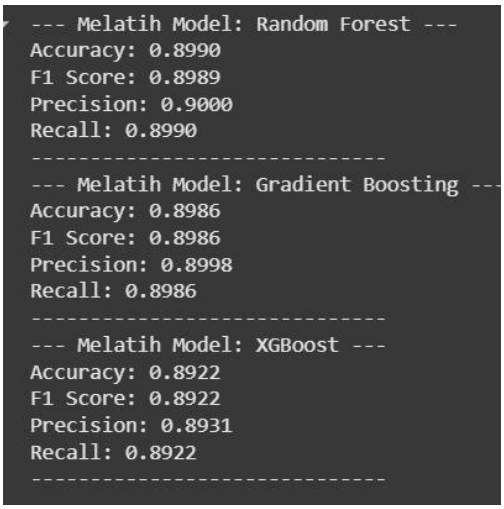
StandardScaler melakukan normalisasi dengan cara mengubah distribusi data agar memiliki mean = 0 dan standar deviasi = 1. Metode ini cocok digunakan ketika data mengikuti distribusi normal.



Gambar 5.1 Penanganan Dengan Penanganan StandardScaler

5.2 MinMaxScaler

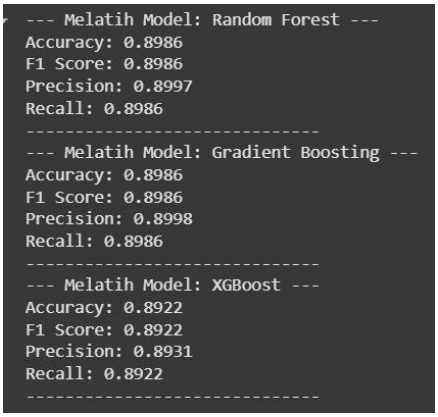
MinMaxScaler mengubah data ke dalam rentang [0, 1]. Teknik ini sangat berguna untuk algoritma yang sensitif terhadap skala fitur.



Gambar 5.2 Modeling Dengan Penanganan MinMaxScaler

5.3 RobustScaler

RobustScaler menggunakan median dan IQR (interquartile range) sebagai dasar normalisasi. Teknik ini cocok saat data memiliki banyak outlier karena tidak terpengaruh oleh nilai ekstrim.



Gambar 5.3 Modeling Dengan Penanganan RobustScaler

5.4 IQR (Interquartile Range)

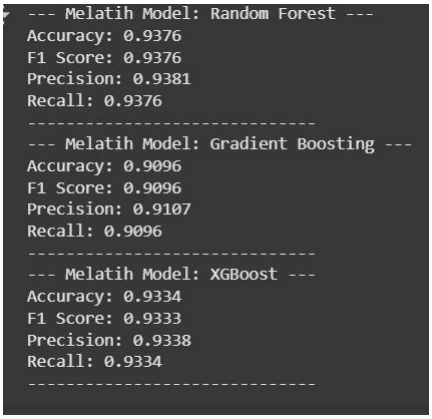
IQR (Interquartile Range) adalah rentang antara kuartil ke-3 (Q3) dan kuartil ke-1 (Q1) dalam distribusi data:

$$\mathbf{IQR} = Q3 - Q1$$

Aturan umum mengenai IQR:

- Batas bawah = Q1 - 1.5 × IQR
- Batas atas = Q3 + 1.5 × IQR

Nilai di luar rentang ini dianggap outlier dan bisa dihapus.



Gambar 5.4 Modeling Dengan Penanganan IQR

5.6 Perbandingan Seluruh Metode

Preprocessing	Model	Accuracy	Precision	Recall	F1 Score
StandardScaler	Random Forest	0,8988	0,8999	0,8988	0,8988
	Gradient Boosting	0,8986	0,8998	0,8986	0,8986

	XGBoost	0,8922	0,8931	0,8922	0,8922
MinMaxScaler	Random Forest	0,899	0,9	0,899	0,8989
	Gradient Boosting	0,8986	0,8998	0,8986	0,8986
	XGBoost	0,8922	0,8931	0,8922	0,8922
RobustScaler	Random Forest	0,8986	0,8997	0,8986	0,8986
	Gradient Boosting	0,8986	0,8998	0,8986	0,8986
	XGBoost	0,8922	0,8931	0,8922	0,8922
IQR	Random Forest	**0,9376**	**0,9381**	**0,9376**	**0,9376**
	Gradient Boosting	0,9096	0,9107	0,9096	0,9096
	XGBoost	0,9334	0,9338	0,9334	0,9333

- **Random Forest** secara konsisten unggul di semua preprocessing.
- **Gradient Boosting** stabil namun sedikit lebih rendah dari Random Forest.
- **XGBoost** sedikit lebih rendah dari Gradient Boosting kecuali saat IQR, di mana performanya meningkat drastis.

Model Random Forest dengan preprocessing IQR (Outlier Removal) memberikan performa terbaik di semua matrik evaluasi. Oleh karena itu, model ini dipilih sebagai model final dalam proyek ini.

BAB VI DEPLOYING

6.1 Streamlit

Proses terakhir yang kami lakukan dalam pengembangan aplikasi ini adalah tahap deployment ke sebuah platform web. Untuk tahap ini, kami memilih menggunakan Streamlit sebagai media deploy karena platform ini menawarkan proses yang relatif mudah, cepat, dan efisien, terutama bagi aplikasi yang berbasis Python. Streamlit memungkinkan kami untuk langsung menampilkan antarmuka pengguna dari script Python yang telah dibuat tanpa perlu menyiapkan infrastruktur frontend secara terpisah. Selain itu, Streamlit juga mendukung integrasi dengan berbagai layanan cloud dan menyediakan dokumentasi yang sangat membantu, sehingga proses publikasi aplikasi ke web dapat dilakukan dengan lebih praktis dan hemat waktu. Kemudahan inilah yang menjadi alasan utama kami memutuskan untuk menggunakan Streamlit sebagai solusi deploy akhir dari proyek ini.



Gambar 6.1 Modeling Dengan Penanganan IQR